

# Pipeline Multimodal para Prognóstico de Lesão Medular com Inteligência Artificial: Uma Arquitetura Baseada em Visão Computacional e Dados Clínicos

Roberlan Oliveira de Carvalho

Programa de Pós-Graduação em Informática, Universidade Federal do Rio de Janeiro (UFRJ)

roberlan.carvalho@gmail.com

**Resumo.** Este trabalho propõe uma Prova de Conceito (PoC) de uma arquitetura multimodal de Inteligência Artificial para apoio ao prognóstico de recuperação motora em lesão medular traumática. A proposta integra imagens de ressonância magnética (MRI) no padrão Digital Imaging and Communications in Medicine (DICOM) e dados clínicos estruturados, como escala ASIA e força motora. O pipeline organiza-se em dois módulos: visão computacional, com extração de representações por ResNet50, detecção de anomalias por Isolation Forest e interpretação por lógica fuzzy; e predição clínica multimodal, baseada em modelos de árvores, como Random Forest e XGBoost. A explicabilidade é apoiada por Grad-CAM e SHAP. A PoC combina imagens DICOM reais com dados clínicos sintéticos, demonstrando viabilidade técnica inicial, sem validade clínica, dependente de dados longitudinais reais.

**Palavras-chave:** Lesão Medular; Inteligência Artificial Explicável; Aprendizado Multimodal; Visão Computacional; Lógica Fuzzy.

**Abstract.** This work proposes a Proof of Concept (PoC) of a multimodal Artificial Intelligence architecture to support motor recovery prognosis in traumatic spinal cord injury. The proposal integrates spinal magnetic resonance imaging (MRI) in the Digital Imaging and Communications in Medicine (DICOM) standard with structured clinical data, such as ASIA scale and motor strength. The pipeline is organized into two modules: computer vision, using ResNet50 for feature extraction, Isolation Forest for anomaly detection, and fuzzy logic for interpretation; and multimodal clinical prediction, based on tree-based models such as Random Forest and XGBoost. Explainability is supported by Grad-CAM and SHAP. The PoC combines real DICOM images with synthetic clinical data, demonstrating initial technical feasibility without clinical validity, which still depends on real longitudinal datasets.

**Keywords:** Spinal Cord Injury; Explainable Artificial Intelligence; Multimodal Learning; Computer Vision; Fuzzy Logic.

## 1. Introdução

A lesão medular traumática é uma condição neurológica de elevada complexidade clínica, marcada por grande variabilidade anatômica, funcional e temporal entre pacientes. A recuperação motora depende de múltiplos fatores concomitantes, como extensão e nível da lesão, compressão medular, edema, sinais imagiológicos sutis, classificação neurológica inicial e trajetória longitudinal de recuperação, o que reduz a efetividade de abordagens únicas, nas quais imagens ou variáveis clínicas são analisadas isoladamente e apresentam apenas parte do fenômeno.

A literatura recente evidencia ganhos de desempenho preditivo quando múltiplas modalidades são combinadas de forma estruturada, ainda que persistam desafios de governança, interpretabilidade e validação externa (KRONES et al., 2025; WARNER et al., 2024). Esse padrão é particularmente relevante na lesão medular, em que sinais de MRI e variáveis neurológicas estruturadas, como a Escala ASIA e a força motora segmentar, carregam informações complementares sobre o estado funcional do paciente (SHIMIZU et al., 2025; LIN et al., 2025). O problema central deste trabalho é duplo: (i) a dificuldade de extrair, de forma robusta, padrões visuais complexos em MRI da coluna vertebral que se correlacionem com desfechos motores futuros; e (ii) a necessidade de arquiteturas de IA mais transparentes para uso médico, aproximando-se de uma lógica de maior auditabilidade operacional, mesmo incorporando deep learning (exigência reforçada por normas como a LGPD e a HIPAA, que restringem o tratamento de dados clínicos sensíveis).

Diante desse cenário, o objetivo deste artigo é propor uma arquitetura multimodal, em nível de Prova de Conceito (PoC), para apoio ao prognóstico de recuperação motora em lesão medular. A arquitetura integra: (i) um módulo de visão computacional baseado em MRI, com extração de atributos por transferência de aprendizado, detecção de anomalias e tradução do escore em categorias linguísticas por lógica fuzzy; (ii) um módulo de predição clínica multimodal, que combina esse sinal com variáveis inspiradas no protocolo EMSCI; e (iii) uma camada de Explicabilidade (XAI), com Grad-CAM para o componente visual e SHAP para o componente tabular. O restante do artigo está organizado da seguinte forma: a Seção 2 discute trabalhos relacionados; a Seção 3 detalha a arquitetura; a Seção 4 descreve a PoC e sua demonstração técnica; e a Seção 5 apresenta as conclusões.

## 2. Trabalhos Relacionados

O avanço do aprendizado multimodal em saúde reforça a relevância de integrar imagens médicas a dados clínicos estruturados. Krones et al. (2025) revisam mais de 50 estudos multimodais, mapeando 17 bases e destacando que a fusão intermediária tende a superar abordagens unimodais, embora sua efetividade dependa da tarefa clínica. Warner et al. (2024) sistematizam desafios centrais do aprendizado multimodal em biomedicina — representação, fusão, alinhamento e coaprendizagem —, reforçando obstáculos de escassez de dados anotados e de avaliação clínica rigorosa. Ambos corroboram a motivação central desta proposta: a fusão entre imagem e dados clínicos agrega valor preditivo, mas exige desenho cuidadoso para não comprometer a governança do sistema.

No domínio da lesão medular, Shimizu et al. (2025) integraram dados clínicos e MRI para prever desfechos neurológicos após cirurgia de lesão cervical, mostrando ganho

discriminativo sobre abordagens unimodais. Lin et al. (2025), em estudo multicêntrico, combinaram radiômica e atributos extraídos com ResNet34 a variáveis clínicas para prever melhora de força muscular, obtendo com Random Forest acurácia de 0,800 e AUC de 0,893. Ambos reforçam, no próprio domínio da lesão medular, a hipótese de que a fusão MRI-clínica pode melhorar o prognóstico funcional, combinando deep learning com modelos baseados em árvores, como na presente proposta.

No campo da explicabilidade, Zhang et al. (2024) propuseram um modelo interpretável para prognóstico de hemorragia intracerebral, combinando Random Forest com SHAP, Grad-CAM e Guided Grad-CAM. Cai et al. (2025) desenvolveram um modelo de fusão multimodal com ResNet50 3D, radiômica e dados clínicos integrados por atenção cruzada para prever sobrevida em câncer de bexiga, validado por SHAP e Grad-CAM em coorte multicêntrica com mais de mil pacientes. Ambos evidenciam que Grad-CAM, para explicação espacial, e SHAP, para atribuição tabular, consolidaram-se como padrão de facto em pipelines multimodais de saúde.

A Tabela 1 compara esses estudos à arquitetura proposta. A diferença central está em três aspectos: foco em prognóstico funcional de lesão medular via variáveis EMSCI; introdução de uma camada fuzzy para tradução linguística da incerteza visual, ausente nos trabalhos citados; e desenho modular e desacoplado, que favorece auditoria intermediária dos artefatos gerados em cada etapa.

Tabela 1. Comparação entre trabalhos relacionados e a arquitetura proposta

| Estudo                | Modalidades                                                           | Modelo preditivo                      | Explicabilidade                                              | Diferencial desta proposta                                                                           |
|-----------------------|-----------------------------------------------------------------------|---------------------------------------|--------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Krones et al. (2025)  | Revisão multimodal (imagem, texto, séries temporais, dados tabulares) | Diversos (estudo de revisão)          | Discute limitações de interpretabilidade como desafio aberto | Aplica os achados da revisão a um pipeline concreto e auditável para lesão medular                   |
| Shimizu et al. (2025) | MRI + dados clínicos (lesão medular cervical)                         | Modelos de aprendizado supervisionado | Não é o foco central do estudo                               | Propõe camada fuzzy de incerteza e XAI dedicado no desenho arquitetural da PoC (Grad-CAM + SHAP)     |
| Lin et al. (2025)     | MRI (ResNet34) + radiômica + dados clínicos                           | Random Forest (AUC = 0,893)           | Não é o foco central do estudo                               | Explora Isolation Forest e lógica fuzzy como camadas intermediárias de interpretação visual          |
| Cai et al. (2025)     | MRI 3D (ResNet50) + radiômica + dados clínicos                        | Fusão por atenção cruzada             | SHAP e Grad-CAM                                              | Adapta a lógica multimodal explicável para uma PoC voltada ao prognóstico funcional em lesão medular |

3. Metodologia (Arquitetura do Sistema)

3.1. Visão geral da arquitetura

A arquitetura organiza-se em dois módulos integrados. O Módulo 1 recebe imagens de MRI da coluna vertebral, extrai atributos visuais por transferência de aprendizado, identifica padrões anômalos por algoritmo não supervisionado e produz um escore imagiológico

traduzido em categoria linguística de incerteza. O Módulo 2 integra esse escore a variáveis clínicas estruturadas e gera a predição de recuperação motora por modelos baseados em árvores. Essa organização em estágios favorece três propriedades: desacoplamento funcional entre visão e predição clínica; reprodutibilidade computacional, pois cada etapa produz artefatos intermediários registráveis; e rastreabilidade analítica, que permite auditar embeddings, escores de anomalia, categorias fuzzy e atribuições de importância.

A Figura 1 sintetiza a organização geral da arquitetura proposta, evidenciando a separação entre o módulo visual, responsável pelo processamento das imagens MRI/DICOM, e o módulo clínico-tabular, responsável pela fusão multimodal e pela estimativa prognóstica.




Figura 1. Arquitetura geral da PoC multimodal proposta para apoio ao prognóstico funcional em lesão medular, integrando o módulo visual baseado em MRI/DICOM ao módulo clínico-tabular para estimativa de recuperação motora.

### 3.1.1. Proveniência de Dados

A confiabilidade de uma arquitetura de apoio à decisão clínica depende diretamente da proveniência e da rastreabilidade dos dados que a alimentam, razão pela qual o pipeline proposto trata essas dimensões como requisitos arquiteturais explícitos, e não como propriedades incidentais do sistema. No Módulo 1, as imagens da coluna vertebral utilizadas para a validação técnica do componente de visão computacional e de detecção de anomalias possuem proveniência pública e aberta, originárias do desafio RSNA 2024 Lumbar Spine Degenerative Classification, disponibilizado pela Radiological Society of North America na plataforma Kaggle, com metadados de aquisição documentados e distribuição irrestrita para fins de pesquisa. Essa camada de dados é adequada à validação de robustez do pipeline visual, mas não substitui uma base clínica de lesão medular traumática com acompanhamento longitudinal. Já no Módulo 2, os dados clínicos e as imagens de ressonância magnética de alta

resolução (sequências T1, T2 e STIR) que fundamentam conceitualmente o protocolo de predição multimodal seguem uma proveniência controlada, restrita e auditável, associada ao consórcio europeu European Multicenter Study about Spinal Cord Injury (EMSCI, 2024), cujo acesso é mediado por comitês de ética, acordos de uso de dados e plataformas de governança como o repositório Synapse. Essa segunda camada exige registro verificável de cada etapa de coleta, anonimização, transferência e processamento dos dados clínicos, de modo que a proveniência, a autorização de acesso e a integridade dos registros possam ser auditadas a qualquer momento. A separação arquitetural entre essas duas camadas de proveniência é deliberada: ela impede que dados públicos e dados sensíveis sejam tratados com o mesmo nível de exigência de governança, e garante que a conformidade regulatória com a Lei Geral de Proteção de Dados (LGPD) e com o Health Insurance Portability and Accountability Act (HIPAA) seja incorporada como restrição de design, e não como camada de conformidade adicionada a posteriori.

Neste trabalho, o protocolo EMSCI é utilizado como referência conceitual para definição das variáveis clínicas simuladas, especialmente a Escala ASIA e a força motora basal, não como fonte direta de dados individuais de pacientes. Assim, a PoC não utiliza registros clínicos reais do consórcio EMSCI, mas apenas se inspira em sua estrutura de acompanhamento neurológico para compor o módulo clínico-tabular e demonstrar a integração multimodal proposta.

### **3.1.2. Repetibilidade e Reprodutibilidade Computacional**

A repetibilidade computacional do pipeline é favorecida por meio do controle estrito de sementes aleatórias (random seeds) em todas as etapas estocásticas dos experimentos, incluindo a inicialização e o ajuste fino da transferência de aprendizado da ResNet50, a execução do algoritmo Isolation Forest para detecção de anomalias e a geração dos dados clínicos sintéticos utilizados na Prova de Conceito. As sementes são fixadas de forma consistente nas bibliotecas Python, NumPy e TensorFlow/Scikit-learn subjacentes a cada componente, de modo que a execução do pipeline completo, sob as mesmas condições de hardware, sistema operacional e versão de dependências, produza resultados numericamente idênticos, independentemente da máquina em que seja executado. Essa propriedade distingue a repetibilidade (a capacidade de reproduzir exatamente o mesmo resultado a partir da mesma execução) da reprodutibilidade científica em sentido mais amplo, assegurada neste trabalho pela publicação completa do código-fonte, bem como das instruções para a execução do projeto em qualquer outro dispositivo com os requisitos adequados, dos hiperparâmetros de treinamento e das versões fixadas de dependências em um repositório público no GitHub, disponível em <https://github.com/roberlancarvalho/lesao-medular-poc> (CARVALHO, 2026). Dessa forma, qualquer pesquisador pode não apenas verificar os resultados relatados, mas também auditar as decisões de implementação que os geraram, requisito cada vez mais exigido em publicações de Inteligência Artificial aplicada à saúde.

## **3.2. Módulo 1 — Visão Computacional**

O primeiro módulo processa imagens de MRI da coluna vertebral em formato DICOM. Como base técnica inicial para organização, pré-processamento e seleção de fatias relevantes, adota-se o ecossistema de dados do desafio RSNA 2024 Lumbar Spine Degenerative

Classification (RSNA, 2024), benchmark amplamente utilizado para classificação e triagem em imagens de coluna vertebral. Após normalização e seleção das fatias sagitais e axiais mais informativas, emprega-se uma ResNet50 pré-treinada e ajustada por transferência de aprendizado para extração de representações profundas de alto nível, estratégia coerente com o volume limitado de dados rotulados em domínios médicos especializados. Os vetores extraídos são submetidos a um detector de anomalias baseado em Isolation Forest, algoritmo adequado a cenários em que anormalidades estruturais são raras, heterogêneas e pouco documentadas, produzindo um escore contínuo que reflete o afastamento do exame em relação ao padrão de referência.

A principal inovação metodológica está na camada de lógica fuzzy aplicada sobre esse escore. Em vez de um limiar binário rígido, que descartaria informação de grau e fragilizaria decisões próximas à fronteira, funções de pertinência fuzzy convertem o escore contínuo em três graus linguísticos: Anomalia Leve, Anomalia Moderada e Anomalia Severa. Essa estratégia tem respaldo na literatura sobre lógica fuzzy em diagnóstico médico, que evidencia sua adequação para modelar imprecisão e ambiguidade em dados clínicos e biológicos (TORRES; NIETO, 2006; ZAITSEVA et al., 2023), aumentando a interpretabilidade clínica do escore e facilitando a comunicação de incerteza a especialistas humanos.

Na PoC atual, a ResNet50 é utilizada como extratora de características pré-treinada, sem ajuste fino supervisionado específico para lesão medular. Assim, os embeddings visuais servem para validação computacional do fluxo, mas não devem ser interpretados como biomarcadores clínicos validados.

O Isolation Forest é empregado como componente de detecção de anomalia sobre os embeddings visuais, mas sua calibração clínica depende de uma coorte real, específica e anotada de lesão medular.

### **3.3. Módulo 2 — Predição Clínica Multimodal**

O segundo módulo integra o escore imagiológico já traduzido em grau fuzzy, a variáveis clínicas estruturadas inspiradas no protocolo EMSCI (European Multicenter Study about Spinal Cord Injury), referência para padronizar a avaliação neurológica e o acompanhamento longitudinal. Entre as variáveis, destacam-se a classificação ASIA (AIS), os escores de força motora por miótomo-chave e atributos clínico-demográficos como idade, nível neurológico e tempo desde o trauma. A fusão ocorre em nível tabular: o escore visual resumido e sua categoria fuzzy passam a atuar como atributo adicional no espaço de predição.

Para a inferência prognóstica, priorizam-se algoritmos baseados em árvores, como Random Forest e XGBoost, justificados por diversos autores por questões como: bom desempenho em dados tabulares heterogêneos mesmo com amostras limitadas; robustez a relações não lineares sem engenharia extensiva de atributos; menor sensibilidade à escala entre variáveis clínicas e o escore imagiológico; e maior compatibilidade com técnicas de explicabilidade baseadas em valores de Shapley (TreeSHAP). Assim, combina-se a capacidade representacional do deep learning visual com a robustez e auditabilidade de modelos tabulares amplamente usados em predição clínica, em linha com estudos aplicados de fusão MRI-clínica em lesão medular (SHIMIZU et al., 2025; LIN et al., 2025).

Uma propriedade metodológica e clínica fundamental dessa arquitetura é o desacoplamento funcional entre a interpretação visual isolada (Módulo 1) e a inferência

preditiva integrada (Módulo 2). Enquanto a classificação fuzzy do primeiro módulo quantifica de forma estrita o escore de anomalia estrutural da medula espinhal a partir dos pixels da imagem, sem sofrer influência de parâmetros externos, o Módulo 2 executa uma fusão tardia em nível tabular em que o quadro clínico do paciente modula de maneira independente e dinâmica o desfecho prognóstico. Na prática médica, esse design permite que uma ressonância magnética interpretada pela lógica fuzzy como “Anomalia Leve” possa ser integrada a um quadro clínico de alta gravidade neurológica, como uma lesão completa classificada como escala ASIA A acompanhada de força motora basal mínima, resultando coerentemente em uma estimativa de “Alto Risco Multimodal” de não recuperação funcional em um ano. Esse comportamento demonstra conceitualmente que o módulo preditivo pode ponderar o contexto multimodal, em vez de replicar diretamente o sinal imagiológico isolado.

### **3.4. Explicabilidade e transparência**

A transparência é tratada como requisito de projeto desde a concepção. No módulo visual, o Grad-CAM (Gradient-weighted Class Activation Mapping) é aplicado sobre as camadas convolucionais da ResNet50 para gerar mapas de calor que destacam as regiões da MRI mais relevantes para a decisão, apoiando inspeção qualitativa e verificação de plausibilidade anatômica, técnica consolidada como referência para interpretação espacial em imagem médica (ZHANG et al., 2024; DEVI et al., 2025). No módulo clínico, o SHAP quantifica a contribuição marginal de cada variável tabular, incluindo o escore convertido em categoria fuzzy e os atributos EMSCI, permitindo leitura individual e global do comportamento do modelo.

A combinação entre Grad-CAM e SHAP atende a uma necessidade central em aplicações médicas multimodais (CAI et al., 2025; ZHANG et al., 2024): fornecer indícios complementares sobre onde o modelo visual concentrou ativação e quais variáveis tabulares influenciaram a predição. Ao integrar essas duas camadas de explicabilidade a uma camada adicional de incerteza fuzzy, a arquitetura aproxima desempenho preditivo e governança algorítmica em um mesmo desenho técnico, característica essencial para a adoção clínica responsável de sistemas de apoio à decisão baseados em IA (GILL et al., 2025; MAKI et al., 2024).

## **4. Prova de Conceito e Demonstração Técnica**

A arquitetura foi materializada em uma Prova de Conceito na forma de aplicação web interativa, desenvolvida em Python com Streamlit, escolhida por sua adequação à prototipagem rápida de pipelines de ciência de dados, com foco em rastreabilidade, inspeção visual e repetibilidade computacional. A interface permite carregar exames DICOM, executar o pipeline visual do Módulo 1, visualizar as saídas explicáveis do Grad-CAM e combinar o escore imagiológico (já convertido em categoria fuzzy) com dados clínicos estruturados para obter a predição prognóstica, acompanhada da explicação SHAP. Cada execução gera ainda um relatório técnico em formato JSON, contendo timestamp, versão da aplicação, origem dos dados, parâmetros clínicos informados, escore de anomalia, classificação fuzzy e probabilidade estimada, reforçando a rastreabilidade experimental discutida na Seção 3.1.2. O código-fonte completo, as dependências e as instruções detalhadas de instalação, execução e

reprodução do pipeline estão documentadas no arquivo README do repositório do projeto (CARVALHO, 2026).

A implementação foi conduzida de forma iterativa, com revisão humana dos módulos de processamento, inferência e visualização, priorizando rastreabilidade, modularidade e reprodutibilidade do código.

A estratégia de validação considera uma limitação concreta do domínio: o acesso a bases clínicas reais com granularidade equivalente ao protocolo EMSCI é fortemente restringido por exigências éticas, legais e institucionais, incluindo normas de proteção de dados sensíveis como a LGPD, no Brasil, e a HIPAA, nos Estados Unidos, que impõem barreiras ao compartilhamento e ao uso secundário de dados clínicos fora do vínculo institucional direto com centros hospitalares e comitês de ética.

Por essa razão, o componente clínico da PoC emprega simulação estruturada de dados (mock data), preservando coerência semântica e distribuições estatísticas plausíveis, sem qualquer vínculo com pacientes reais. Já as imagens de MRI utilizadas no Módulo 1 são DICOM reais, empregadas para validar a robustez do pipeline visual, a consistência dos artefatos explicáveis e a repetibilidade das etapas de processamento. Esse desenho híbrido não substitui uma validação clínica completa, mas é adequado aos objetivos de uma PoC: verificar a integração funcional entre módulos, a estabilidade do fluxo computacional e a viabilidade de migração futura para dados reais, anonimizados e validados em ambiente multicêntrico (SHIMIZU et al., 2025; LIN et al., 2025; GILL et al., 2025). Para explicitar o grau de maturidade científica de cada componente, a Tabela 2 resume o status atual da PoC, o tipo de dado utilizado e a principal limitação associada.

Tabela 2. Maturidade dos componentes da PoC

| Componente                  | Status atual | Tipo de dado                        | Limitação principal                           |
|-----------------------------|--------------|-------------------------------------|-----------------------------------------------|
| Leitura DICOM               | Implementado | Imagens reais RSNA 2024             | Base não específica de trauma medular         |
| Pré-processamento de imagem | Implementado | DICOM convertido e normalizado      | Padronização ainda limitada                   |
| ResNet50                    | Implementado | Imagem convertida para RGB          | Pré-treinada em ImageNet                      |
| Grad-CAM                    | Implementado | Ativações da CNN                    | Requer validação anatômica por especialista   |
| Isolation Forest            | Implementado | Embeddings visuais                  | Precisa calibração com coorte real            |
| Lógica fuzzy                | Implementado | Escore de anomalia                  | Funções de pertinência heurísticas            |
| Random Forest               | Implementado | Dados clínicos sintéticos           | Sem validade clínica                          |
| SHAP                        | Implementado | Modelo treinado em dados sintéticos | Explica o modelo da PoC, não validade clínica |
| Relatório JSON              | Implementado | Saídas da execução                  | Precisa versionamento experimental completo   |



Figura 2. Interface da PoC em Streamlit, exibindo a seleção de MRI/DICOM, a entrada de variáveis clínicas, os indicadores de escore de anomalia, classificação fuzzy visual, probabilidade estimada de recuperação, risco multimodal e visualização Grad-CAM.

Como cenário demonstrativo, a PoC permite selecionar uma imagem DICOM do dataset RSNA 2024, informar manualmente a Escala ASIA e a força motora basal, executar o pipeline visual e obter uma predição multimodal. A saída inclui o escore de anomalia da MRI, sua tradução fuzzy em categoria linguística, a probabilidade estimada de recuperação motora em um ano, o risco multimodal associado, o mapa Grad-CAM e a explicação SHAP das variáveis tabulares. Esse cenário não representa uma avaliação clínica real, mas demonstra a integração funcional dos componentes arquiteturais propostos.

Cabe destacar que, na versão atual da PoC, os componentes computacionais foram implementados como módulos executáveis, e não apenas como regras aleatórias: a leitura DICOM é realizada sobre imagens reais do RSNA 2024; a extração visual utiliza uma ResNet50 pré-treinada; o escore de anomalia é calculado por Isolation Forest; e o módulo clínico emprega Random Forest treinado sobre dados clínicos sintéticos semanticamente coerentes com variáveis de avaliação neurológica, como ASIA e força motora. Além disso, a explicabilidade tabular é produzida por SHAP sobre o modelo treinado. Ainda assim, os resultados permanecem sem validade clínica, pois o treinamento clínico utiliza dados sintéticos e a calibração do componente visual não foi realizada com um estudo de acompanhamento real de pacientes com lesão medular traumática.

## 5. Conclusão e Trabalhos Futuros

Este artigo apresentou uma PoC de arquitetura multimodal para apoio ao prognóstico de recuperação motora em lesão medular, integrando visão computacional sobre MRI/DICOM e dados clínicos estruturados inspirados no protocolo EMSCI. A arquitetura organiza-se em um módulo visual, responsável pela leitura DICOM, extração de características por CNN pré-treinada, detecção de anomalia e tradução fuzzy do escore visual, e um módulo clínico-tabular, responsável por combinar esse escore com variáveis como ASIA e força motora. A

implementação em Streamlit demonstrou a viabilidade técnica inicial da integração entre esses componentes e da geração de artefatos explicáveis por Grad-CAM e SHAP, embora a validade clínica ainda dependa de dados reais, calibração e validação longitudinal.

Como trabalhos futuros, destacam-se três direções: a substituição integral das simulações por inferências em tempo real sobre dados clínicos reais, sob governança institucional e protocolos de anonimização compatíveis com a LGPD e a HIPAA; a validação multicêntrica em ambiente hospitalar, replicando o padrão de estudos correlatos que já demonstraram ganhos com fusão MRI-clínica em lesão medular (SHIMIZU et al., 2025; LIN et al., 2025); e a extensão da modelagem para uma abordagem longitudinal do tipo time-to-event, capaz de capturar a dinâmica temporal da recuperação funcional ao longo de múltiplos pontos de avaliação, em vez de uma predição estática de desfecho único.

Ferramentas de IA generativa, especificamente o OpenAI Codex e o Claude Code (Anthropic), foram utilizadas como apoio colaborativo no processo de engenharia de software, incluindo a implementação da interface gráfica e a orquestração de código. Todas as decisões metodológicas, curadoria bibliográfica, validação técnica e revisão final permaneceram sob responsabilidade do autor.

## Referências

CAI, L.; BAI, R.; CAO, Q.; SUN, W.; WANG, F.; LIU, X.; LIANG, B.; JIANG, M.; WANG, G.; SHAO, Q.; JIANG, X.; WANG, C.; CHEN, C.; TAN, Z.; WU, Q.; BAO, M.; YU, H.; LI, P.; YANG, X.; LU, Q. A non-invasive MRI-based multimodal fusion deep learning model (MF-DLM) for predicting overall survival in bladder cancer: a multicentre retrospective study. *eClinicalMedicine*, v. 90, art. 103640, 2025. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S2589537025005747>. Acesso em: 09 jul. 2026.

CARVALHO, R. O. lesao-medular-poc: repositório do protótipo experimental do Pipeline Multimodal para Prognóstico de Lesão Medular. GitHub, 2026. Disponível em: <https://github.com/roberlancarvalho/lesao-medular-poc>. Acesso em: 04 ago. 2026.

DEVI, S. R.; JUSTUS, J. J.; VANATHI, M.; VEERAMALLU, B.; ARUNA, V.; MANJUNATH, T. C.; SAPAYEV, V. O. U.; BANU, S. An Explainable Machine Learning Model for Early Detection of Brain Tumors: Integrating Multi-Modal Medical Imaging and Intelligent Feature Fusion. *Engineering, Technology & Applied Science Research*, v. 15, n. 5, p. 26448-26453, 2025. Disponível em: <https://etasr.com/index.php/ETASR/article/view/11539>. Acesso em: 09 jul. 2026.

EMSCI — EUROPEAN MULTICENTER STUDY ABOUT SPINAL CORD INJURY. About EMSI. 2024. Disponível em: <https://www.emsci.org/>. Acesso em: 09 jul. 2026.

GILL, S. S.; PONNIAH, H. S.; GIERSTEIN, S.; ANANTHARAJ, R. M.; NAMIREDDY, S.; KILLILEA, J.; RAMSAY, D. S. C.; SALIH, A.; THAVARAJASINGAM, A.; SCURTU, D.; JANKOVIC, D.; RUSSO, S.; KRAMER, A.; THAVARAJASINGAM, S. G. The diagnostic and prognostic capability of artificial

intelligence in spinal cord injury: A systematic review. *Brain and Spine*, v. 5, art. 104208, 2025. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11871462/>. Acesso em: 09 jul. 2026.

KRONES, F.; MARIKKAR, U.; PARSONS, G.; SZMUL, A.; MAHDI, A. Review of multimodal machine learning approaches in healthcare. *Information Fusion*, v. 114, art. 102690, 2025. Disponível em: <https://doi.org/10.1016/j.inffus.2024.102690>. Acesso em: 09 jul. 2026.

LIN, F.; WANG, K.; LAI, M.; WU, Y.; CHEN, C.; WANG, Y.; WANG, R. Multicenter study on predicting postoperative upper limb muscle strength improvement in cervical spinal cord injury patients using radiomics and deep learning. *Scientific Reports*, v. 15, art. 5805, 2025. Disponível em: <https://www.nature.com/articles/s41598-024-72539-0>. Acesso em: 09 jul. 2026.

MAKI, S.; FURUYA, T.; INOUE, M.; SHIGA, Y.; INAGE, K.; EGUCHI, Y.; ORITA, S.; OHTORI, S. Machine Learning and Deep Learning in Spinal Injury: A Narrative Review of Algorithms in Diagnosis and Prognosis. *Journal of Clinical Medicine*, v. 13, n. 3, p. 705, 2024. Disponível em: <https://www.mdpi.com/2077-0383/13/3/705>. Acesso em: 09 jul. 2026.

RSNA — RADIOLOGICAL SOCIETY OF NORTH AMERICA. RSNA 2024 Lumbar Spine Degenerative Classification. Kaggle, 2024. Disponível em: <https://www.kaggle.com/competitions/rsna-2024-lumbar-spine-degenerative-classification>. Acesso em: 09 jul. 2026.

SHIMIZU, T.; INOMATA, K.; SUDA, K.; HARMON, S. M.; KOMATSU, M.; OTA, M.; USHIROZAKO, H.; MINAMI, A.; MAKI, S.; ENDO, T.; YAMADA, K.; IWASAKI, N.; TAKAHASHI, H.; YAMAZAKI, M.; KODA, M. A multimodal machine learning model integrating clinical and MRI data for predicting neurological outcomes following surgical treatment for cervical spinal cord injury. *European Spine Journal*, v. 34, n. 9, p. 3747-3755, 2025. Disponível em: <https://link.springer.com/10.1007/s00586-025-08873-2>. Acesso em: 09 jul. 2026.

TORRES, A.; NIETO, J. J. Fuzzy Logic in Medicine and Bioinformatics. *Journal of Biomedicine and Biotechnology*, v. 2006, art. ID 91908, 2006. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC1559939/>. Acesso em: 09 jul. 2026.

WARNER, E.; LEE, J.; HSU, W.; SYEDA-MAHMOOD, T.; KAHN JR., C. E.; GEVAERT, O.; RAO, A. Multimodal Machine Learning in Image-Based and Clinical Biomedicine: Survey and Prospects. *International Journal of Computer Vision*, v. 132, n. 9, p. 3753-3769, 2024. Disponível em: <https://link.springer.com/10.1007/s11263-024-02032-8>. Acesso em: 09 jul. 2026.

ZAITSEVA, E.; RABCAN, J.; KVASSAY, M.; LEVASHENKO, V. A New Fuzzy-Based Classification Method for Use in Smart/Precision Medicine. *Bioengineering*, v. 10, n. 7, art. 838, 2023. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10376790/>. Acesso em: 09 jul. 2026.

ZHANG, H.; YANG, Y.-F.; SONG, X.-L.; HU, H.-J.; YANG, Y.-Y.; ZHU, X.; YANG, C. An interpretable artificial intelligence model based on CT for prognosis of intracerebral hemorrhage: a multicenter study. *BMC Medical Imaging*, v. 24, n. 1, art. 170, 2024. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11234657/>. Acesso em: 09 jul. 2026.