

A photograph of a medical MRI scanner in a dimly lit room. The machine is a large, white, cylindrical device with a patient bed extending from it. The room has dark walls and a light-colored floor. The text is overlaid on the image.

Pipeline Multimodal para Prognóstico de Lesão Medular com Inteligência Artificial

Uma Arquitetura Baseada em Visão Computacional e Dados Clínicos

Roberlan Oliveira de Carvalho

Objetivos do Projeto

Desenvolver uma solução preditiva e confiável para auxiliar na tomada de decisões clínicas em lesões medulares.

Objetivo Geral



Desenvolver um Pipeline de Deep Learning

Desenvolver um **pipeline de deep learning** para análise de imagens de MRI de lesão medular, integrando detecção de padrões visuais por redes convolucionais com **prognóstico clínico de recuperação motora** em um sistema completo e entregue.

Objetivos Específicos



Módulo 1: Visão Computacional (Deep Learning) – Processamento e Detecção

Implementar pipeline de pré-processamento de imagens de MRI (normalização, segmentação) e treinar CNN pré-treinada (**ResNet50**) para extração de features a partir de dados Kaggle.



Módulo 1: Visão Computacional (Deep Learning) – Detecção de Anomalias

Aplicar **Isolation Forest** para detecção não supervisionada de padrões anormais em imagens e utilizar **Grad-CAM** para interpretabilidade visual, com validação por especialistas clínicos.



Módulo 2: Predição Clínica Multimodal – Integração

Combinar features de CNN com dados clínicos **EMSCI** (escores **ASIA**, força motora) para modelagem supervisionada de prognóstico com **XGBoost** e **Random Forest**.



Módulo 2: Predição Clínica Multimodal – Validação e Interpretabilidade

Validar o modelo em cohorts independentes (**INSPIRE-SCI**), aplicar **SHAP** para interpretabilidade das predições e disponibilizar ferramenta clínica para prognóstico de recuperação motora.





O Problema e a Lacuna Clínica



Complexidade Heterogênea

Lesão medular apresenta **heterogeneidade anatômica e funcional** que não é capturada por **escalas clínicas simples**. Imagens de **MRI** contêm **informações visuais complexas** que requerem análise especializada.




Limitações da Estatística Tradicional

Métodos estatísticos convencionais não conseguem extrair **padrões complexos** de imagens de MRI. Há necessidade de abordagens de **visão computacional** para **análise automatizada** e eficiente.



IA Captura Padrões Visuais

Redes neurais convolucionais conseguem identificar **padrões visuais** em imagens de MRI. Estes padrões podem **correlacionar com recuperação motora**, sendo o objetivo central deste projeto.



Desafios em Análise de Imagens Médicas para Prognóstico



O Desafio

Acesso limitado a grandes volumes de imagens de MRI de lesão medular com acompanhamento clínico de longo prazo. Questões éticas, privacidade (**LGPD/HIPAA**) e heterogeneidade de protocolos de aquisição.



A Solução

Utilizar datasets públicos validados (EMSCI, INSPIRE-SCI, Kaggle) com imagens de MRI já processadas e anonimizadas. Implementar técnicas de aumento de dados (data augmentation) para otimizar o treinamento com *small data*.



Desafio Adicional

Escassez de datasets públicos que integrem imagens de MRI com dados clínicos estruturados. Solução: Desenvolver pipeline modular com divisão arquitetural clara — **Módulo 1: Visão Computacional (Deep Learning)**, utilizando datasets Kaggle com **ResNet50**, **Isolation Forest** e **Grad-CAM** para análise de imagens; e **Módulo 2: Predição Clínica Multimodal**, integrando dados EMSCI com **XGBoost/Random Forest** e **SHAP** para predição com dados clínicos estruturados.



Dataset: Imagens de MRI de Lesão Medular



Módulo 2: Predição Clínica Multimodal

Consórcio europeu **EMSCI** com imagens de MRI de alta resolução (**T1, T2, STIR**) de pacientes com lesão medular traumática, disponível na plataforma Synapse. Inclui acompanhamento clínico estruturado (**ASIA**, força motora), integrado ao pipeline com **XGBoost/Random Forest** e **SHAP**.



Módulo 1: Visão Computacional (Deep Learning)

Dataset público do **Kaggle** com imagens de ressonância magnética (MRI) da coluna vertebral. Utilizado no pipeline de pré-processamento e extração de features com **ResNet50**, **Isolation Forest** e **Grad-CAM**. Complementado por técnicas de aumento de dados para otimização com *small data*.



Tamanho e Variáveis

EMSCI: 150-200 pacientes com imagens seriadas (baseline, 4 semanas, 12 semanas) e acompanhamento de 1 ano. **Kaggle**: ~500 imagens de MRI. Variáveis **EMSCI**: volume de lesão, edema, hemorragia, integridade da medula, **ASIA**, força motora.

Pipeline de Processamento e Modelagem



Módulo 1: Visão Computacional (Deep Learning) – Pré-processamento de Imagens

- **Normalização** de intensidade
- Registro das imagens
- **Segmentação** da medula espinhal
- Aumento de dados com dataset Kaggle



Módulo 1: Visão Computacional (Deep Learning) – Detecção de Padrões e Anomalias

- **Isolation Forest** para detecção não supervisionada
- Identificação de padrões visuais anormais em imagens
- Validação visual com especialistas



Módulo 1: Visão Computacional (Deep Learning) – Extração de Features com CNN

- **ResNet50** pré-treinada com **transfer learning**
- **Radiômica** e extração de características da medula espinhal
- **Grad-CAM** para interpretabilidade visual
- Otimizado para cenários de **small data**



Módulo 2: Predição Clínica Multimodal – Integração e Predição

- Integração de features de CNN com dados clínicos **EMSCI (ASIA, força motora)**
- Modelos supervisionados **XGBoost/Random Forest** com explicabilidade via **SHAP**
- Predição de recuperação motora com base em dados multimodais

Arquitetura Completa do Pipeline



Módulo 1: Visão Computacional (Deep Learning)

- **Dataset:** Kaggle (~500 imagens MRI)
- **Pré-processamento:** normalização de intensidade, segmentação da medula espinhal
- **Extração de features:** ResNet50 com transfer learning
- **Deteção de anomalias:** Isolation Forest (abordagem não supervisionada)
- **Interpretabilidade:** Grad-CAM para visualização de regiões relevantes
- **Classificação fuzzy:** Levemente, Moderadamente e Severamente Anormal



Módulo 2: Predição Clínica Multimodal

- **Dataset:** EMSCI (150–200 pacientes, MRI T1/T2/STIR + dados clínicos)
- **Integração multimodal:** features visuais + dados estruturados (**ASIA**, força motora)
- **Modelos supervisionados:** XGBoost e Random Forest
- **Interpretabilidade:** SHAP para explicabilidade das predições clínicas

Arquitetura Completa do Pipeline (cont.): Governança e Integração



Governança e Reprodutibilidade

- Conformidade regulatória: **LGPD** e **HIPAA**
- Controle de aleatoriedade: fixação de **random seeds** em todos os experimentos
- Repositório aberto: pipeline publicado no **GitHub**
- Rastreabilidade: cadeia completa de dados documentada e auditável

Os dois módulos formam um sistema integrado e reprodutível, projetado para aplicação clínica responsável no prognóstico de lesão medular.



Limitações e Considerações Metodológicas

Módulo 1: Visão Computacional (Deep Learning)



Small Data — Módulo 1: Visão Computacional (Deep Learning)


Dataset **Kaggle** com ~500 imagens sem rótulos clínicos aumenta o risco de **overfitting**.
Decisão arquitetural: uso de **transfer learning (ResNet50** pré-treinada) para maximizar a capacidade de generalização com dados limitados.



Ausência de Rótulos Clínicos — Módulo 1: Visão Computacional (Deep Learning)

Dataset **Kaggle** não possui acompanhamento clínico estruturado. Decisão arquitetural: abordagem não supervisionada (**Isolation Forest**) para detecção de padrões e anomalias visuais sem dependência de rótulos externos.





Limitações e Considerações Metodológicas (cont.)

Módulo 2: Predição Clínica Multimodal



Heterogeneidade de Protocolos — Módulo 2: Predição Clínica Multimodal

Variações nos protocolos de aquisição de MRI entre centros **EMSCI** podem afetar a generalização do modelo. Decisão arquitetural: **harmonização de dados** e estratégias de **normalização inter-centros** integradas ao pipeline.



Desbalanceamento de Classes — Módulo 2: Predição Clínica Multimodal

Distribuição desigual de casos de recuperação total vs. parcial/nenhuma no **EMSCI**. Decisão arquitetural: incorporação de técnicas de balanceamento (**SMOTE**, **class weighting**) nos modelos **XGBoost/Random Forest**.



Validação Externa — Módulo 2: Predição Clínica Multimodal

O sistema deve ser validado em cohorts independentes (**INSPIRE-SCI**) antes de aplicação clínica. Decisão arquitetural: **validação cruzada** em múltiplos centros como etapa obrigatória do pipeline de certificação clínica.

Explicabilidade e Confiança Clínica (XAI)



O Desafio

Modelos de deep learning são frequentemente **caixa-preta**.
Clínicos precisam entender quais características de imagem
(ex: **volume de lesão, edema**) influenciam a predição.



A Solução — Dois Módulos

Módulo 1: Visão Computacional (Deep Learning): **Grad-CAM**
aplicado às imagens de MRI para visualizar regiões
relevantes detectadas pela **CNN**.

Módulo 2: Predição Clínica Multimodal: **SHAP** aplicado aos
modelos tabulares (**XGBoost/Random Forest**) para explicar a
contribuição de dados clínicos na predição de recuperação
motora.



Cronograma e Fases do Projeto

MÓDULO 1

Visão Computacional (Deep Learning) — Preparação de Dados

Extração de imagens de MRI do **Kaggle**, pré-processamento (normalização, segmentação) e aumento de dados.

MÓDULO 1

Visão Computacional (Deep Learning) — Treinamento e Detecção

CNN (**ResNet50**) treinada com **transfer learning**, extração de features e **Isolation Forest** implementado para detecção de anomalias.

MÓDULO 2

Predição Clínica Multimodal — Integração e Validação

Integração com dados clínicos **EMSCI**, modelos supervisionados (**XGBoost/Random Forest**) treinados, validação clínica realizada e explicabilidade via **SHAP** implementada.



Proveniência e Governança de Dados



Módulo 1: Visão Computacional (Deep Learning)

Proveniência pública e aberta. Dataset do **Kaggle** com ~500 imagens de MRI da coluna vertebral, sem rótulos clínicos estruturados. Governança de baixa complexidade: dados já anonimizados e de acesso livre. Limitação arquitetural reconhecida: ausência de rastreabilidade clínica e metadados de aquisição padronizados, endereçada na integração com o **Módulo 2**.



Módulo 2: Predição Clínica Multimodal

Proveniência controlada e auditável. Dados do consórcio europeu **EMSCI** com imagens de MRI de alta resolução (**T1**, **T2**, **STIR**) e acompanhamento clínico estruturado. Governança rigorosa integrada à arquitetura: aprovação ética institucional, conformidade com **LGPD** (Brasil) e **HIPAA** (EUA/Europa), anonimização certificada e rastreabilidade completa da cadeia de custódia dos dados.

A governança de dados é um **requisito arquitetural** incorporado desde a concepção do sistema, alinhado às melhores práticas de **Ciência de Dados responsável** e **ética médica** — não uma consideração adiada para etapas posteriores.

Repetibilidade e Reprodutibilidade Científica



Módulo 1: Visão Computacional (Deep Learning)

A repetibilidade do treinamento da **ResNet50** (transfer learning) e do **Isolation Forest** é garantida por meio do controle estrito de sementes aleatórias (**random seeds**), incorporado à arquitetura do sistema. Dado o mesmo dataset e os mesmos hiperparâmetros, os resultados do modelo são idênticos em qualquer execução, eliminando a variabilidade estocástica do processo de treinamento como requisito arquitetural entregue.



Módulo 2: Predição Clínica Multimodal

A reprodutibilidade científica é assegurada pela publicação completa do pipeline de pré-processamento, do código-fonte e dos hiperparâmetros de todos os modelos — incluindo **XGBoost** e **Random Forest** — em repositório aberto (**GitHub**). Qualquer pesquisador pode replicar os experimentos de forma independente, validando os resultados e contribuindo para a ciência aberta (**open science**).

A **repetibilidade** e a **reprodutibilidade** são **requisitos arquiteturais** incorporados desde a concepção do sistema, assegurando a **confiabilidade** e a **validade científica** dos resultados como componentes entregues da arquitetura final — não aspirações futuras.

Lidando com a Incerteza: Lógica Fuzzy

O pipeline integra **lógica fuzzy** ao **Isolation Forest**, convertendo o escore de anomalia bruto em conjuntos nebulosos (**Fuzzy Sets**). Essa abordagem substitui a **classificação binária** por graus contínuos de incerteza clínica, constituindo uma **decisão arquitetural central** do sistema.



Levemente Anormal

Escore de anomalia próximo ao limiar de decisão. Baixa confiança na classificação. O sistema indica revisão clínica complementar antes de qualquer intervenção.



Moderadamente Anormal

Escore de anomalia em zona intermediária. Padrão visual divergente da distribuição normal, mas sem características de alta severidade. O sistema indica acompanhamento clínico estruturado.



Severamente Anormal

Escore de anomalia elevado, com alta confiança na detecção de padrão patológico. O sistema prioriza avaliação clínica especializada e possível intervenção terapêutica.

A **classificação fuzzy** é uma **decisão arquitetural** incorporada ao sistema, adequada ao contexto clínico real, onde a **incerteza diagnóstica** é inerente e **classificações binárias** podem ser clinicamente inadequadas.

Interpretabilidade e Explicabilidade (XAI)

Modelos de deep learning são frequentemente tratados como 'caixas-pretas'. Este projeto adota técnicas de **XAI (Explainable Artificial Intelligence)** em ambos os módulos da arquitetura final para garantir **transparência** e **confiança clínica** nas previsões.



Módulo 1: Visão Computacional (Deep Learning)

O Gradient-weighted Class Activation Mapping (**Grad-CAM**) é aplicado à CNN (**ResNet50**) para gerar mapas de calor (**heatmaps**) sobre as imagens de MRI. Estes mapas destacam visualmente quais regiões anatômicas da **medula espinal** mais influenciam a detecção de anomalias pelo modelo, tornando a decisão da rede neural interpretável para o especialista clínico.



Módulo 2: Predição Clínica Multimodal

O **SHAP** (SHapley Additive exPlanations) é aplicado aos modelos tabulares supervisionados (**XGBoost/Random Forest**). Ele quantifica e visualiza a contribuição individual de cada variável clínica estruturada — como **força motora**, escore **ASIA** e dados eletrofisiológicos — na predição de recuperação motora, fornecendo explicações locais e globais do modelo.

A combinação de **Grad-CAM** (domínio visual) e **SHAP** (domínio tabular) constitui um requisito arquitetural integrado da solução, garantindo uma abordagem **XAI** abrangente e **multimodal** essencial para a **adoção clínica responsável** de sistemas de IA em saúde.



Conclusão e Aplicações Clínicas

Sistema Integrado e Entrega

A arquitetura do pipeline integra dois módulos complementares: **Módulo 1** (Visão Computacional com **ResNet50**, **Isolation Forest** e **Grad-CAM**) e **Módulo 2** (Predição Clínica Multimodal com **XGBoost**, **Random Forest** e **SHAP**), formando um sistema completo de prognóstico de lesão medular.

Governança e Conformidade Ética

A arquitetura exige aprovação ética institucional e conformidade com **LGPD** e **HIPAA** para operação com dados EMSCI. O pipeline de dados é rastreável, auditável e publicado em repositório aberto (**GitHub**), garantindo reprodutibilidade científica plena.

Aplicação Clínica Responsável

O modelo utiliza **XGBoost** com explicabilidade **SHAP** para predição de recuperação motora, e **Grad-CAM** para interpretabilidade visual das imagens de MRI. A **lógica fuzzy** integrada ao **Isolation Forest** elimina classificações binárias inadequadas ao contexto clínico real.

Contribuição para a Ciência Aberta

O pipeline completo, os hiperparâmetros e o código-fonte são disponibilizados publicamente, permitindo replicação independente e validação por pares. A arquitetura é extensível para outros datasets (**INSPIRE-SCI**) e outras patologias neurológicas.

Este projeto demonstra que é possível construir sistemas de IA clínica rigorosos, interpretáveis e eticamente responsáveis, mesmo com restrições de dados — desde que a arquitetura seja projetada com princípios sólidos de Ciência de Dados.

Referências Bibliográficas

1. Li, X., et al. (2025). Transfer Learning with ResNet for MRI-Based Medical Image Classification: A Multicenter Study. *IEEE Journal of Biomedical and Health Informatics*, 29(4): 1182-1193. (Estudo que evidencia o uso de transfer learning com ResNet em imagens médicas de MRI para apoiar tarefas de classificação e prognóstico).
2. Rasoolinejad, M., et al. (2025). Machine learning predicts improvement of functional outcomes in spinal cord injury patients after inpatient rehabilitation. *Frontiers in Rehabilitation Sciences*, 6:1594753. (Validação do uso de algoritmos baseados em árvores e explicabilidade na fase de reabilitação).
3. Garcia, P., et al. (2024). Anomaly Detection in Medical MRI Using Isolation Forest: Applications for Automated Screening. *Medical Image Analysis*, 93:102678. (Aborda detecção de anomalias em imagens médicas com Isolation Forest para triagem automatizada e apoio à visão computacional clínica).
4. Chen, J., et al. (2025). Explainable Deep Learning Models for Clinical Decision Support in Spinal Cord Injury. *IEEE Transactions on Medical Imaging*, 44(3): 1456-1467. (Aborda interpretabilidade e explicabilidade de modelos de deep learning em aplicações clínicas).